

数据基本要求

1. 每条 session 数据，有效交互轮次 ≥ 2 轮
2. 首条消息 role 正常，不得为 assistant/tool
3. 每条 session 中，至少一次结构化工具调用
4. 所有调用的工具都有明确定义，schema 完整
5. 去掉最后一轮后，tool result 和 tool call 配对率=100%
6. 机器轮占比 $< 25\%$ ，即 $(\text{cron}+\text{heartbeat}+\text{no_reply user 轮}) / \text{user 轮} < 25\%$

1. 模型要求

1. 模型要求：GPT、GEMINI、CLAUDE
2. 型号要求：GPT-5 以上、GEMINI-3 以上、CLAUDE-4.5 以上版本

1. 数据内容要求

2. 真实用户交互

我们优先接受真实用户与 Agent 系统交互产生的轨迹数据。以下特征会被作为合成数据的检测信号：

内容维度：

- 用户消息像模板题库或批量生成的 pattern（如“帮我开发一个完整 XXX 系统+功能清单”千篇一律）
- 对话中缺乏现场性、追问、修正、环境上下文
- 消息格式过度结构化、风格高度一致

行为维度：

- 工具调用全部成功、零报错（真实环境中工具调用会遇到报错、路径不存在、权限问题、重试等）
- 文件路径和 URL 全部通用化、可替换（如 `/home/user/project/file.py`、`example.com`）
- 每轮消息自包含，不依赖上下文（真实对话会引用前文、省略已知信息、使用指代）
- 任务线性推进、无偏移、无意外（真实任务常有中途调整目标、追加需求、发现新问题后转向）

1. 高优代码、搜索场景

我们优先接受真实用户使用 Agent 系统完成代码工程、搜索等任务交互类轨迹数据。拒绝 roleplay、GUI 等场景方向。

1. 概念明晰

2. 轮次定义

1. 有效轮次（effective turns）包括以下类型的交互：

交互类型	说明
User → Assistant	用户提问，Agent 回答
Assistant → Tool → Tool Result	Agent 调用工具并获得结果
用户追问与修正	用户对 Agent 回答进行追问、补充或修正

1. 机器轮定义：

- heartbeat 轮：user 命中模板且对应 assistant 回固定哨兵串、无 tool_use、无实质推理
- cron 轮：user 命中模板且对应 assistant 无 tool_use、无实质推理
- no_reply user 轮：user 侧无新信息，即该轮为空/纯标点/纯机械确认/完全重复上一条 user；或 assistant 侧空转，即该轮 assistant 仅回哨兵 / 空，且无 tool、无推理

1. session 定义

1. 定义：session 是指用户针对一个完整任务与 Agent（AI 助手）进行的一次连续交互过程，从用户发起任务到任务完成或终止
2. 首条消息 role 正常，messages.role 不得为 assistant 或 tool
3. 每个 Session 必须有唯一的 session_id
4. 一个完整的 Session 包含：
 - System Prompt（系统提示词）：Agent 的角色设定和能力描述
 - 至少两轮 User → Assistant 交互：用户输入和 Agent 回复
5. 若一条记录的轮次序列是另一条的连续子序列（即更完整版本的截取片段），以最完整的一条作为唯一 session

6. 机器轮 / user 轮 < 25%; 其中机器轮包括 heartbeat 轮, cron 轮, no_reply user 轮; user 轮为真实发起轮数, 即所有 role=user 消息中, 剔除掉: tool_result 载体轮, harness 元注入轮

1. Tool Use 定义与要求

4.3.1 Tool Use 组成部分:

1. 有明确的工具定义 (Tool Schema)

系统中必须定义可用的工具列表, 每个工具须包含:

- name: 工具名称 (必须有明确语义, 禁止使用 tool1、helper、action 等含义模糊的名称)
- description: 工具功能描述
- parameters: 参数定义, 含参数名、类型、说明

1. 有结构化的工具调用记录 (Tool Call)

Agent 发起的工具调用必须是结构化的 (如 tool_use/function_call 格式), 包含:

- 被调用的工具名称
- 调用参数 (JSON 格式)
- 纯自然语言描述的“工具调用”不计入有效工具调用

1. 有完整的工具返回结果 (Tool Result)

每次工具调用必须有对应的返回结果, 包含:

- 工具执行的输出内容
- 执行状态 (成功/失败/错误信息)

4.3.2 Tool Use 数量要求:

- 每个 Session 至少包含 1 次结构化工具调用 (有明确工具定义的前提下)

4.3.3 Tool 配对率要求:

- 所有调用的工具需在前置有明确定义, 不能出现调用的工具不在前置工具列表的情况
- 去掉最后一轮后, tool result 和 tool call 配对率 = 100%, 其中配对率 = 存在对应 tool_result 的 tool_call 数量 ÷ tool_call 总数; 其中, 尾轮以最后一个 other 出现为准

1. 字段列表

分类	字段	说明
session	session_id	session 唯一标识符
	messages / conversation / trajectory	完整的消息序列
	model / model_name	使用的模型名称和版本
message	role	消息角色: system / user / assistant / tool
	content	消息内容（文本或结构化对象）
System Prompt	System message	Agent 角色设定、能力描述、行为指引
	Tool definitions / Tool schema	可用工具列表及其参数定义
tool call	tool_use / function_call	工具调用记录（工具名 + 参数）
	tool_result / observation	工具执行结果
其他	thinking / reasoning	Agent 的推理思考过程
	metadata	元数据（时间戳、token 用量、provider 等）
	task_type / domain	任务类型和领域标签

1. 数据集内去重标准

2. 精确重复去重

比较 system prompt + user messages + assistant responses + tool calls + tool results，轮次序列完全一致视为精确重复。

1. 子集去重

同一 session 如果一条记录的轮次序列是另一条的连续子序列（即截取片段），仅保留最完整的版本。

1. token 计算逻辑

适用于按 token 量进行结算的合作方，我方的 token 计算方式为：

1. 我方将首先对数据集进行【条款六】中的精确去重和子集去重
2. 加总【实际调用的 tool call definition token】及【所有 message token】，为实际 token 数
3. 若出现二进制图片编码 base64，我方将剔除 base64 的部分不计入 token，其余部分正常计算 token

1. 交付文件格式要求

1. 支持 .json 或 .jsonl 格式
2. 编码统一使用 UTF-8
3. 每条记录的 JSON 必须合法可解析
4. 传输压缩包统一为 tar.gz
5. 规范化文件夹路径，复杂的路径需要附上路径说明

工具调用示例（推荐格式）：

```
{
  "role": "assistant",
  "content": "让我搜索一下相关信息。",
  "tool_calls": [
    {
      "id": "call_001",
      "type": "function",
      "function": {
        "name": "web_search",
        "arguments": "{\"query\": \"Python async best practices\"}"
      }
    }
  ]
}
```

工具返回示例：

```
{
  "role": "tool",
  "tool_call_id": "call_001",
  "content": "搜索结果: ..."
}
```

1. 严禁行为

工具结果捏造：工具返回的内容是假的（如伪造的 ID、整数统计值、规律性数据），而非真实执行结果

结果与声明矛盾：Agent 声称操作完成，但工具输出显示失败

模型伪装：model 字段标注的模型与实际生成模型不一致（如标注 glm-5 实际使用 glm-4.7-flash）

模型幻觉：工具调用出现幻觉，如调用工具为编造、工具调用结果为幻觉